Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»



Лабораторная работа №4 по дисциплине «Методы машинного обучения»

Выполнил: студент группы ИУ5-22М Вей Пхьоу Ту

Задание

- 1. Выбрать произвольный набор данных (датасет), предназначенный для построения рекомендательных моделей.
- 2. Опираясь на материалы лекции, сформировать рекомендации для одного пользователя (объекта) двумя произвольными способами.
- 3. Сравнить полученные рекомендации (если это возможно, то с применением метрик).

Текст программы и экранные формы

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.metrics import confusion_matrix
from sklearn.metrics.pairwise import cosine_similarity, euclidean_distances, manhattan_distances
from surprise import SVD, Dataset, Reader
import seaborn as sns
import matplotlib.pyplot as plt
from matplotlib_venn import venn2
%matplotlib inline
sns.set(style="ticks")
```

```
[32] data=pd.read_csv('googleplaystore.csv', sep=",")
[33] #размер датасета
data.shape
(10841, 13)
```

| | Арр | Category | Rating | Reviews | Size | Installs | Туре | Price | Content Rating | Genres | Last Updated | Current Ver | Android Ver |
|---|---|----------------|--------|---------|------|-------------|------|-------|-------------------|---------------------------------|------------------------|--------------------------|-----------------|
| 0 | Photo Editor & Candy Camera & Grid & ScrapBook | ART_AND_DESIGN | 4.1 | 159 | 19M | 10,000+ | Free | 0 | Everyone | Art & Design | January 7, 2018 | 1.0.0 | 4.0.3 and up |
| 1 | Coloring book moana | ART_AND_DESIGN | 3.9 | 967 | 14M | 500,000+ | Free | 0 | Everyone | Art & Design;Pretend Play | January 15, 2018 | 2.0.0 | 4.0.3 and up |
| 2 | U Launcher Lite - FREE Live Cool Themes, Hide | ART_AND_DESIGN | 4.7 | 87510 | 8.7M | 5,000,000+ | Free | 0 | Everyone | Art & Design | August 1, 2018 | 1.2.4 | 4.0.3 and up |
| 3 | Sketch - Draw & Paint | ART_AND_DESIGN | 4.5 | 215644 | 25M | 50,000,000+ | Free | 0 | Teen | Art & Design | June 8, 2018 | Varies with device | 4.2 and up |

[35] list(zip(data.columns, [i for i in data.dtypes]))

```
[('App', dtype('0')),
  ('Category', dtype('0')),
  ('Rating', dtype('float64')),
  ('Reviews', dtype('int64')),
  ('Size', dtype('0')),
  ('Installs', dtype('0')),
  ('Type', dtype('0')),
  ('Price', dtype('0')),
  ('Content Rating', dtype('0')),
  ('Genres', dtype('0')),
  ('Last Updated', dtype('0')),
  ('Current Ver', dtype('0')),
  ('Android Ver', dtype('0'))]
```

```
[36] # Колонки с пропусками
     hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
     hcols_with_na
     ['Rating', 'Type', 'Genres', 'Current Ver', 'Android Ver']
[37] df = data[data['Genres'].notnull()]
     df = df[~df['Genres'].str.isspace()]
[38] App= df['App'].values
    App[0:5]
     array(['Photo Editor & Candy Camera & Grid & ScrapBook',
            'Coloring book moana',
            'U Launcher Lite - FREE Live Cool Themes, Hide Apps',
            'Sketch - Draw & Paint', 'Pixel Draw - Number Art Coloring Book'],
           dtype=object)
[39] Genres= df['Genres'].values
     Genres[0:5]
     array(['Art & Design', 'Art & Design; Pretend Play', 'Art & Design',
             'Art & Design', 'Art & Design; Creativity'], dtype=object)
[41] Installs= df['Installs'].values
     Installs[0:5]
     array(['10,000+', '500,000+', '5,000,000+', '50,000,000+', '100,000+'],
           dtype=object)
[42] %%time
     tfidfv = TfidfVectorizer()
     matrix = tfidfv.fit_transform(Genres)
     matrix
     CPU times: user 47.6 ms, sys: 0 ns, total: 47.6 ms
     Wall time: 63 ms
```

```
[43] class SimpleKNNRecommender:
         def __init__(self, X_matrix, X_Genres, X_App, X_Installs):
             Входные параметры:
             X_matrix - обучающая выборка (матрица объект-признак)
             #Сохраняем параметры в переменных объекта
             self._X_matrix = X_matrix
             self.df = pd.DataFrame(
                 {'Genres': pd.Series(X Genres, dtype='str'),
                 'App': pd.Series(X_App, dtype='str'),
                 'Installs': pd.Series(X_Installs, dtype='str'),
                 'dist': pd.Series([], dtype='float')})
         def recommend_for_single_object(self, K: int, \
                     X_matrix_object, cos_flag = True, manh_flag = False):
             Метод формирования рекомендаций для одного объекта.
             Входные параметры:
             К - количество рекомендуемых соседей
             X_{matrix}-object - строка матрицы объект-признак, соответствующая объекту
             cos_flag - флаг вычисления косинусного расстояния
```

```
scale = 1000000
[43]
             # Вычисляем косинусную близость
             if cos_flag:
                 dist = cosine_similarity(self._X_matrix, X_matrix_object)
                 self.df['dist'] = dist * scale
                 res = self.df.sort_values(by='dist', ascending=False)
                 # Не учитываем рекомендации с единичным расстоянием,
                 # так как это искомый объект
                 res = res[res['dist'] < scale]</pre>
             else:
                 if manh flag:
                     dist = manhattan_distances(self._X_matrix, X_matrix_object)
                 else:
                     dist = euclidean_distances(self._X_matrix, X_matrix_object)
                 self.df['dist'] = dist * scale
                 res = self.df.sort_values(by='dist', ascending=True)
                 # Не учитываем рекомендации с единичным расстоянием,
                 # так как это искомый объект
                 res = res[res['dist'] > 0.0]
             # Оставляем К первых рекомендаций
             res = res.head(K)
             return res
```

```
[44] Genres[0]

'Art & Design'
```

```
[45] mc_matrix = matrix[0]
    mc_matrix
```

```
[46] skr1 = SimpleKNNRecommender(matrix, Genres, App, Installs)
```

[47] rec1 = skr1.recommend_for_single_object(5, mc_matrix) rec1

| | Genres | Арр | Installs | dist |
|-------|----------------------------------|---------------------------------------|----------|---------------|
| 23 | Art & Design; Action & Adventure | Mcqueen Coloring pages | 100,000+ | 801421.625333 |
| 2111 | Art & Design; Action & Adventure | Mcqueen Coloring pages | 100,000+ | 801421.625333 |
| 10438 | Art & Design; Creativity | Dolphin and fish coloring book | 500,000+ | 789039.398405 |
| 26 | Art & Design;Creativity | Colorfit - Drawing & Coloring | 500,000+ | 789039.398405 |
| 4 | Art & Design;Creativity | Pixel Draw - Number Art Coloring Book | 100,000+ | 789039.398405 |

```
[48] # При поиске с помощью Евклидова расстояния
rec2 = skr1.recommend_for_single_object(5, mc_matrix, cos_flag = False)
rec2
```

| | Genres | Арр | Installs | dist |
|------|----------------------------------|--|----------|---------------|
| 2111 | Art & Design; Action & Adventure | Mcqueen Coloring pages | 100,000+ | 630203.736369 |
| 23 | Art & Design; Action & Adventure | Mcqueen Coloring pages | 100,000+ | 630203.736369 |
| 7027 | Art & Design;Creativity | UNICORN - Color By Number & Pixel Art Coloring | 500,000+ | 649554.619097 |
| 26 | Art & Design;Creativity | Colorfit - Drawing & Coloring | 500,000+ | 649554.619097 |
| 4 | Art & Design;Creativity | Pixel Draw - Number Art Coloring Book | 100,000+ | 649554.619097 |

| | Genres | Арр | Installs | dist |
|-------|--------------------------|--|----------|---------------|
| 10438 | Art & Design;Creativity | Dolphin and fish coloring book | 500,000+ | 912685.941941 |
| 9 | Art & Design;Creativity | Kids Paint Free - Drawing Fun | 10,000+ | 912685.941941 |
| 7027 | Art & Design;Creativity | UNICORN - Color By Number & Pixel Art Coloring | 500,000+ | 912685.941941 |
| 43 | Art & Design;Creativity | Paint Splash! | 100,000+ | 912685.941941 |
| 26 | Art & Design; Creativity | Colorfit - Drawing & Coloring | 500,000+ | 912685.941941 |